麻雀のポリシー関数に適したネットワークモデルの構築と評価

東京大学総合文化研究科　清水大志, 田中哲朗

はじめに

AlphaGo Zeroのような自己対戦による学習で，強い麻雀プレイヤは作れるのか？

強化学習には大量の計算機を使った実験が必要になる．あるゲームを学習させる前に，そのゲームの性質を持つ小さいゲーム(今回はミニ麻雀)を教師あり学習で学習させて，適したネットワークモデルを求める方法を提案する．

ミニ麻雀のルール

・使用する牌の種類は萬子のみ
・手牌の枚数は基本的に8枚
・ロンあがりや，ポンなどの鳴きは存在しない
・ツモ牌は手持ち以外の牌から等確率で引く
・役は，タンヤオ，一盃口，対々和，チャンタのみ
・あがりの役の個数をvとしたとき，もらえる報酬rは基本点をcとして$r = 2^v c$
・プレイの目的は割引された累積報酬和Rの期待値を最大化すること(ここでは報酬が与えられるのがあがったときのみなので，スタートから n 手であがり，割引率をγとすると$R = \gamma^n r$となる)

教師あり学習

ミニ麻雀においては，手牌から1枚捨てた時の手牌の組み合わせから，累積報酬和の期待値を求めることができる．これはvalue Iterationと呼ばれる方法で求めた．役があるときとないときで，最善手が変わる手牌は10389個のうち6570個ある．
その価値の差がもっとも大きい手牌は

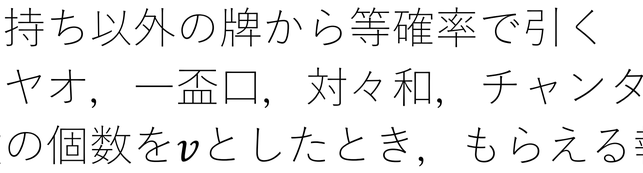

役なし時の最善手は4萬(0.768)だが，役あり時は5萬(2.703)

ポリシー関数に適切なネットワーク構造を見つけるため，以下の3つの構造を考える.それぞれoptunaという自動最適化ツールを用いて，良い結果を出したモデルである．

(1)多層MLP

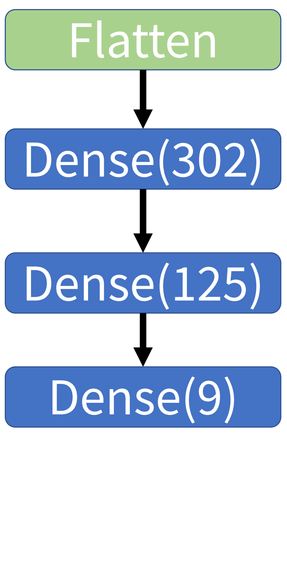

(2)conv1d+Dense

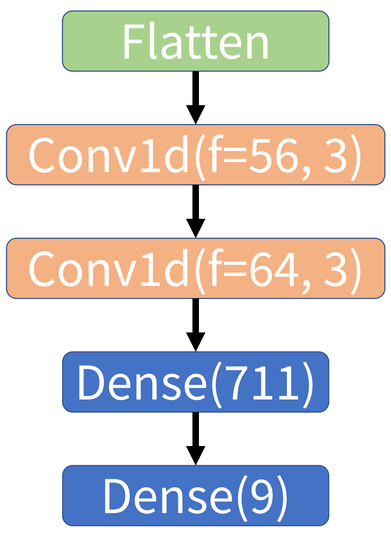

(3)conv2d+Dense

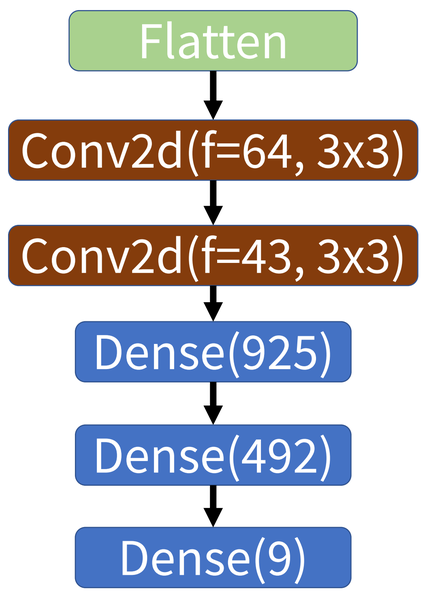

全結合層の出力層の活性化関数は softmax 関数で，それ以外では ReLU を用いる.
探索範囲として，全結合層のユニット数は50から1000，畳み込み層のフィルタの枚数は8から64，畳み込み層の繰り返し数は1から4，全結合層の繰り返し数は1か2としている.

麻雀においては手牌の入力方法にも複数の方法が考えられる.
ここでは先行研究の形も含め，3種類を比較した．それぞれ「手牌モード」と表記する.

例

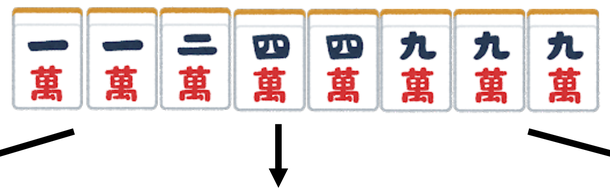

	0枚	1枚	2枚	3枚	4枚
1m	0,	0,	1,	0,	0]
2m	0,	1,	0,	0,	0]
3m	1,	0,	0,	0,	0]
4m	0,	0,	1,	0,	0]
5m	1,	0,	0,	0,	0]
6m	1,	0,	0,	0,	0]
7m	1,	0,	0,	0,	0]
8m	1,	0,	0,	0,	0]
9m	0,	0,	0,	1,	0]

手牌モード**1**

	1枚	2枚	3枚	4枚
1m	1,	1,	0,	0]
2m	1,	0,	0,	0]
3m	0,	0,	0,	0]
4m	1,	1,	0,	0]
5m	0,	0,	0,	0]
6m	0,	0,	0,	0]
7m	0,	0,	0,	0]
8m	0,	0,	0,	0]
9m	1,	1,	1,	0]

手牌モード**2**

	1m	2m	3m	4m		8m	9m
1枚目	[1,	0,	0,	0,	…	0,	0]
2枚目	[1,	0,	0,	0,	…	0,	0]
3枚目	[0,	1,	0,	0,	…	0,	0]
4枚目	[0,	0,	0,	1,	…	0,	0]
5枚目	[0,	0,	0,	1,	…	0,	0]
6枚目	[0,	0,	0,	0,	…	0,	1]
7枚目	[0,	0,	0,	0,	…	0,	1]
8枚目	[0,	0,	0,	0,	…	0,	1]

手牌モード**3**

各モデルにおいて教師あり学習をおこなった
- 10389通りのうち，75%をtrainデータ，25%をtestデータ
- エポック数は1000回（1エポックは配牌からあがるまで）
- 損失関数はcategorical cross entropy
- $\gamma = 0.9, c = 1$とした

各手牌モード，モデルにおける正解率（役なし）

名前	手牌モード 1	手牌モード 2	手牌モード 3
多層 MLP	0.848	0.847	0.793
conv1d + Dense	0.855	0.847	0.822
conv2d + Dense	0.846	0.853	0.828
築地ら [1]	0.807	x	x
cao ら [2]	x	0.828	x

先行研究[1, 2]をミニ麻雀に適用したものよりも高い正解率を得られた．また役ありにおいてもほぼ同程度の正解率が得られた

[1] 築地毅, 柴原一友: CNN 麻雀-麻雀向け CNN 構成の有効 性, ゲームプログラミングワークショップ 2017 論文集, 2017, pp.163-170 (2017)
[2] Gao, Shiqi, et al.: Supervised Learning of Imperfect Information Data in the Game of Mahjong via Deep Convolutional Neural Networks, Information Processing Society of Japan (2018), (2018)

提案したモデルを用いた強化学習

先ほどと対応するネットワーク構造を使って強化学習により価値関数を学習させた．強化学習のアルゴリズムとしてはDQNを用いている．その実装としてOpen AI baselinesのものを使用した.

・手牌から1枚牌を捨てて，1枚引くのを1ステップとし，3×10^6 ステップ学習させた.
・あがったら $2^v c$ (今回は$c = 100$)の報酬を与える.
・切れない牌を切ろうとした時は-100の報酬とし，その時の手牌は変わらない.

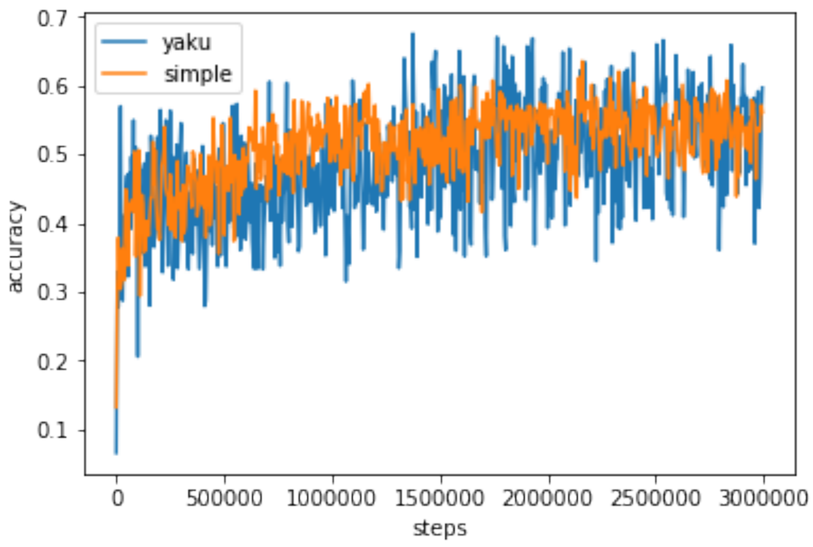

上記は手牌が5枚の時の結果で，教師あり学習と比べて低い正解率となった．手牌が8枚のときも同様の結果である.
原因としてはstep数が足りない，切れない牌を切ろうとした時のペナルティが高すぎる，などが考えられる.

（なお，この研究で用いたコードは https://github.com/minnsou/gpw2019 で公開している）
（牌画はいらすとや https://www.irasutoya.com/2017/02/blog-post_8.html から頂きました）